NyFlow

Minimum deadheading, Maximum flow

Equipo de Proyecto:
Daniel Pantoja Joaristi
Jorge Hernández Palop
Marco Casteleiro Trigueros
Álvaro Arbona Rodríguez
Carlos Jabalquinto Hernán-Gómez

Febrero, 2026

Índice

1. IDEAS PRINCIPALES 4
1.1. ¿Qué es «NyFlow»? 4
1.2. ¿Por qué hacemos esto? 4
1.3. Nuestra propuesta de valor 4
1.4. Segmentación de clientes 4
1.4.1. Posibles clientes 4
1.4.2. Segmentación de los clientes 4
1.4.3. Nicho principal y secundario 5
1.5. Marca y eslogan 5
1.6. Canales de comunicación que usaremos: 5
2. INVERSIÓN INICIAL NECESARIA Y COSTES 5
2.1. Inversión Inicial Requerida 5
2.2. Distribución del Capital 6
2.3. Costes Operativos Anuales (Mantenimiento) 6
3. MODELO Y DATOS 6
3.1. ¿Qué datos vamos a usar? 6
3.2. Análisis de los datos 6
3.2.1. Distribución después de la agregación temporal 7
3.2.2. Evolución de la demanda por mes 7
3.2.3. Influencia del clima sorbe la demanda a lo largo del día 8
3.2.4. Registro de vehículos 8
3.2.5. Duración de los viajes 9
3.2.6. Distribución de las horas de trabajo 9
3.2.7. Precios y beneficios 10
3.3. ¿Qué modelo de deep learning usaremos? 10
3.4. Resumen de Componentes 11
3.4.1. 1. Gated Residual Network (GRN) 11
3.4.2. 2. Variable Selection Networks (VSN) 11
3.4.3. 3. Interpretable Multi-Head Attention 11
3.4.4. 4. Quantile Regression 11
3.5. ¿Cómo encajan los datos con nuestro modelo? 11
3.6. Otros modelos que podríamos usar: 12
4. ANÁLISIS DEL MERCADO Y LA COMPETENCIA 12
4.1. Panorama del Mercado 12
4.2. Matriz Comparativa 13
4.3. Nuestra Ventaja Competitiva: El Efecto «Caja de Cristal» 13
4.4. Análisis DAFO: 14
5. ANÁLISIS FINANCIERO Y ESTRATEGIAS 14
5.1. ¿Cuál será nuestro método de ingresos? 14
5.2. Estructura de Precios 14
5.3. Justificación del Precio 15

5.4. Estrategias de captación y fidelidad 15
5.5. Análisis del Punto Muerto (Break-even) 15
5.5.1. Definición de Parámetros 15
5.5.2. Resultado del Cálculo 15
5.6. Gastos y resultados financieros esperados 15
5.6.1. Justificación de las Proyecciones 16
5.6.2. Proyecciones a 3 Años (P&L) 16
5.6.3. Justificación de Gastos 16
5.7. Conclusión de Viabilidad 16
6. ROADMAP 17
6.1. Fase 1 (hasta mediados de Febrero) 17
6.2. Fase 2 (hasta finales de Abril) 17
6.2.1. Entrenamiento del modelo 17
6.2.2. La aplicación 17
6.2.3. Flujo de datos 17
7. BIBLIOGRAFÍA Y WEBGRAFÍA 18

1. IDEAS PRINCIPALES

1.1. ¿Qué es «NyFlow»?

«NyFlow» es una herramienta software diseñada por un equipo de estudiantes para facilitar a los conductores de servicios de transporte de NYC predicciones de la demanda de sus servicios en los distintos distritos de la ciudad, con el objetivo de poder abastecer la alta demanda en algunas franjas horarias y poder evitar un exceso de oferta de otros momentos del día.

1.2. ¿Por qué hacemos esto?

Según estudios recientes, a lo largo del último año han aumentado los viajes en taxi y VTC en un 12%. Sin embargo, la tasa de utilización se mantiene estancada[1] según reportan Uber y Lyft, por lo que el aumento de demanda no se traduce en una mejora salarial, con unos ingresos bajos según los estándares de Nueva York. Esto se explica en parte porque muchas veces los conductores no saben cuándo y dónde estar para recoger a un cliente.

1.3. Nuestra propuesta de valor

Desde el equipo de «NyFlow» proponemos una herramienta software potenciada con un modelo de deep learning que permite a cualquier conductor saber en su franja horaria cuáles son las estimaciones del precio y la demanda de su sector, proporcionando además mapas fácilmente interpretables que ayudan a conocer la situación en el resto de servicios y zonas.

1.4. Segmentación de clientes

1.4.1. Posibles clientes

Podemos separar nuestros clientes en grandes VTC y el servicio de taxis de NYC (Modelo de empresa B2B), o enfocarlo directamente al consumidor final (modelo B2C).

1.4.2. Segmentación de los clientes

Si enfocamos nuestro producto a empresas de transporte, podemos enfocarla a taxistas o a VTC con alguna adaptación mínima. Se basaría en una negociación directa, contactándoles nosotros mediante canales de comunicación ya sean correos o LinkedIn. Estas empresas se beneficiarían de nuestra aplicación pudiendo ofrecer servicios nuevos a sus conductores.

En cambio, si lo enfocamos al consumidor final (conductores), podemos encontrar distintos tipos de usuarios:

- Jóvenes de 18 a 25 años: Son una minoría en el mundo de los taxistas, un 20%, tienen contacto frecuente con redes sociales. Este segmento utilizarían la aplicación para ver qué días tendrían más ganancias, pero suponiendo que este segmento suele tener múltiples trabajos, creemos que no están dispuestos a cambiarse de zona. Por tanto, la aplicación debe ser capaz de mostrar datos de manera entendible de una zona concreta.
- Adultos de 25 a 50 años: La mayoría de los usuarios se concentrarían aquí, aproximadamente el 60%. Como medio de captación se usarían anuncios físicos o correos electrónicos. Este público demanda sugerencias de lugares estratégicos donde situarse para aumentar sus ganancias diarias. Con este tipo de uso, es fácil imaginar cómo se vería mejorada la experiencia con

panoramas de toda NY que mostrasen los puntos de interés. Este segmento serían nuestros usuarios principales.

- Usuarios de edad avanzada: También suponen una minoría, el último 20%. Este sector consume principalmente anuncios físicos, sin embargo, no enfocaríamos nuestras primeras campañas de marqueting en ellos sabiendo que no son usuarios recurrentes de nuevas tecnologías.

1.4.3. Nicho principal y secundario

Con un equipo reducido de 5 estudiantes es muy difícil llegar a empresas como «Uber», las cuales ya tienen investigaciones en esta rama. Teniendo en cuenta el escenario anterior, la decisión más lógica es un negocio B2C enfocado en los conductores, ya que es más fácil llegar a ellos vía anuncios y asegurar ingresos lo antes posible.

1.5. Marca y eslogan

- Marca: «NyFlow» es resultado de fusionar las siglas de Nueva York y la palabra en inglés *flow*, esta última ya que refleja de manera sencilla nuestro objetivo de maximizar el flujo de circulación y uso de estos servicios.
- Eslogan: «Minimum deadheading, Maximum flow» refleja en 4 palabras toda nuestra propuesta de minimizar el número de vehículos en servicio vacíos.

1.6. Canales de comunicación que usaremos:

Principalmente usaremos publicidad física en aeropuertos o espacios donde se concentre mucha actividad de Uber y taxistas. Además de usando publicidad vía aplicaciones móviles que llegaran a los conductores directamente.

2. INVERSIÓN INICIAL NECESARIA Y COSTES

Para el despliegue de **NyFlow**, hemos definido una estructura de capital eficiente que prioriza la robustez tecnológica sobre el gasto administrativo.

2.1. Inversión Inicial Requerida

La capitalización inicial necesaria asciende a **$35,000**. Esta cantidad cubre el despliegue de la infraestructura de datos, el cumplimiento legal en la jurisdicción de Nueva York. No tenemos en cuenta el marketing, si se tuviese en cuenta estos costes aumentarían.

2.2. Distribución del Capital

Categoría	Coste (USD)	Descripción Detallada
Infraestructura IA	[$12,000]	[Abrir un servidor en AWS con una BBDD para hacer inferencia]
Desarrollo de la app	$8,000	Licencias de software, herramientas de despliegue (CI/CD).
Legal y Registro	$5,000	Constitución de la sociedad en NYC, protección de marca (IP) y redacción de términos legales para conductores.
Reserva de Emergencia	$10,000	Fondo de maniobra para imprevistos técnicos o pivotaje en la estrategia de captación.
Total	**$35,000**	**Inversión inicial Total**

2.3. Costes Operativos Anuales (Mantenimiento)

El mantenimiento de la plataforma requiere un flujo constante de **$45,000 anuales** (3,750$/mes), desglosados de la siguiente manera:

- **Computación de IA:** $1,500/mes para la inferencia en tiempo real del modelo TFT y guardar los datos en una BBDD suficientemente grande.
- **Flujos de Datos y APIs:** $1,000/mes para integración con servicios de geolocalización y clima.
- **Soporte y Administración:** $1,250/mes para herramientas de gestión de usuarios y marketing de retención.

3. MODELO Y DATOS

En este apartado detallaremos la parte técnica del proyecto, ya sean modelos y los datos de los que podríamos disponer.

3.1. ¿Qué datos vamos a usar?

Los datos provienen de la base de datos oficial del gobierno de de Nueva York, extraídos usando webscrapping en su página web. Hemos extraídos datos de todos los viajes tanto de VTC como taxis de los últimos 5 años.

3.2. Análisis de los datos

Aquí mostraremos algunas conclusiones que hemos sacado de los datos tras un análisis exploratorio:

3.2.1. Distribución después de la agregación temporal

Hemos probado distintas agregaciones temporales (segmentar cada 30min, 1 hora, entre otras). Todas las distribuciones son parecidas y elegir una u otra afectará principalmente a la segunda fase del proyecto. Observando por ejemplo una distribución de segmentación de 45 minutos, vemos que la demanda, nuestro principal objetivo de predicción, sigue una función periódica, lo cual ayuda para hacer predicciones. En la siguiente imagen se puede observar como evoluciona la demanda con el paso del tiempo (el eje x representa cada indice temporal, no está en horas)

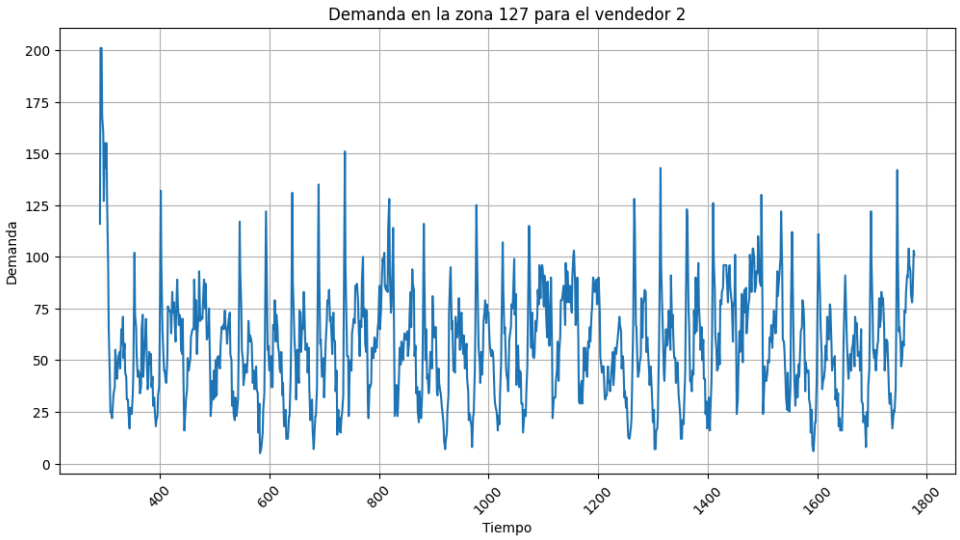

Figura 1: Demanda vs Tiempo.

3.2.2. Evolución de la demanda por mes

Analizando la demanda a lo largo de los últimos años, podemos apreciar que la demanda de taxis amarillos ha crecido un poco desde 2021 (donde era casi nula debido al Covid-19). A pesar de ello, la demanda de vehículos de alto volumen es un 400-500% de la demanda de taxis. Esto sugiere que los pasajeros prefieren claramente empresas como Uber o Lyft a los taxis tradicionales.

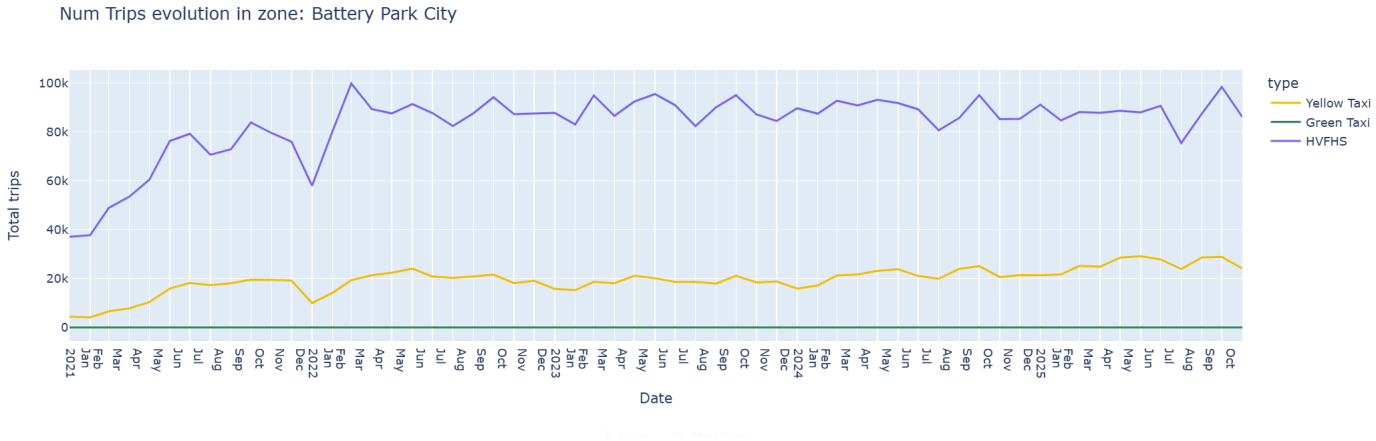

Figura 2: Demanda vs Tiempo vs Estado meteorológico.

3.2.3. Influencia del clima sorbe la demanda a lo largo del día

Además, hemos tenido también en cuenta el estado meteorológico de la zona en cuestión para analizar su influencia. Tomando las líneas negras como base, podemos observar que en días lluviosos (gráfica superior, color azul) la demanda no es muy diferente, solo un poco menor (menos gente sale a la calle cuando llueve). En cambio, en días de nieve, la demanda se reduce considerablemente, casi un 50%, muy posiblemente debido a la obstrucción de las vías urbanas por culpa de la nieve acumulada.

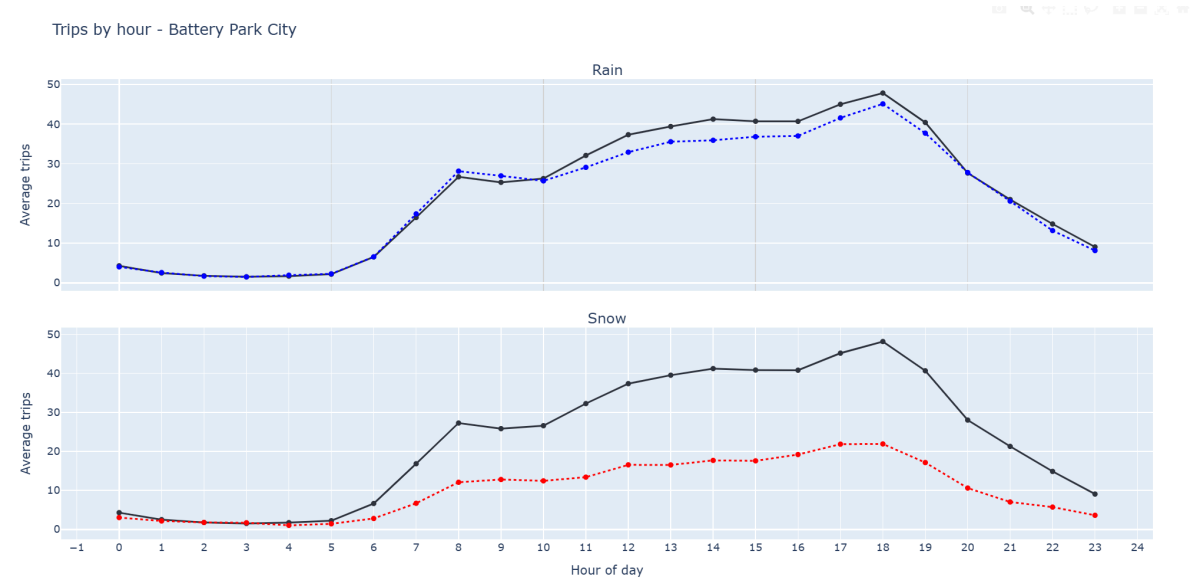

Figura 3: Demanda vs Hora vs Estado meteorológico.

3.2.4. Registro de vehículos

Habiendo analizado dicho aumento de demanda, cabría esperar un aumento proporcional del número de vehículos registrados, y así es: para vehículos de alto volumen, la cantidad aumentó un 400% desde 2021 (coincidiendo con la demanda). Algo curioso que podemos observar es la invariabilidad de los registros de taxis amarillos, que apenas ha crecido desde 2021.

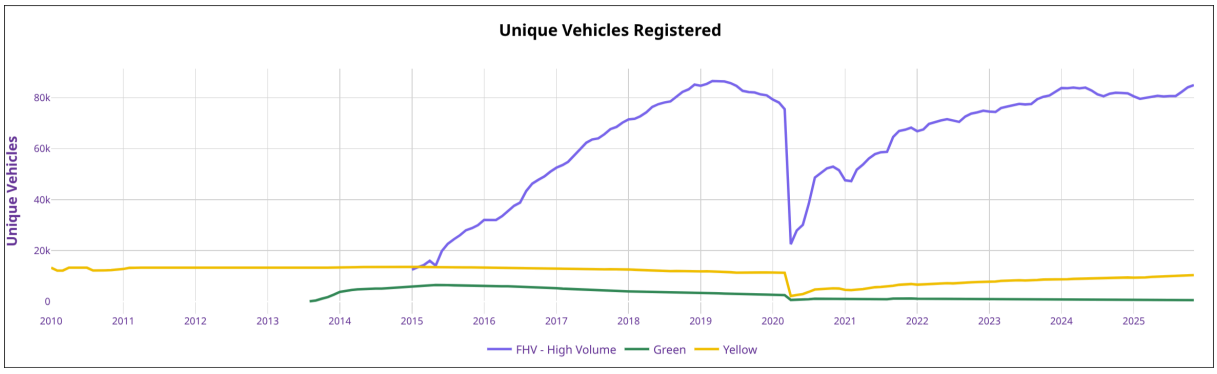

Figura 4: Vehículos registrados vs Tiempo.

3.2.5. Duración de los viajes

Analizando ahora la duración de los viajes, vemos que se mueven en el rango de 10-20 minutos, y no varía considerablemente entre distintos tipos de vehículos (taxi amarillo, verde y vehículos de alto volumen).

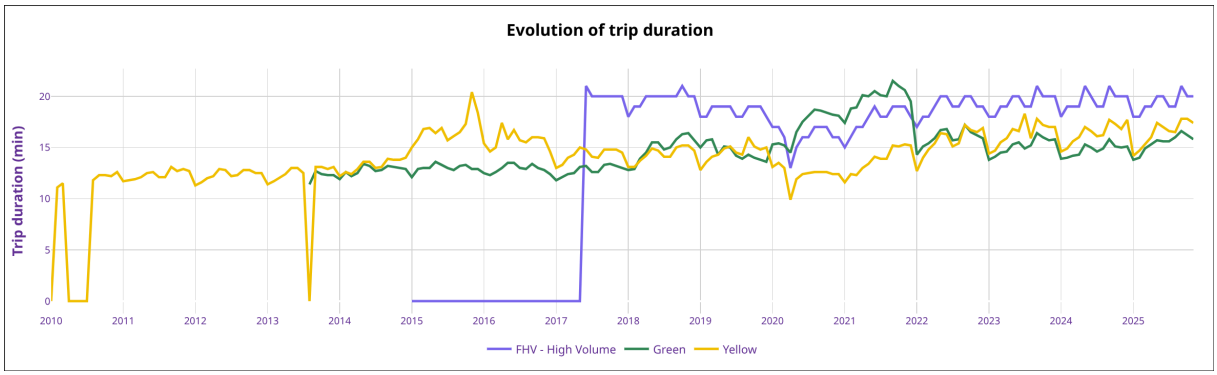

Figura 5: Duración de los viajes vs Tiempo.

3.2.6. Distribución de las horas de trabajo

Como podemos ver, en 2020 hubo una marca extraña debida a la pandemia, en la cual, al no poder salir a la calle en situaciones normales, el uso de transporte se disminuyó drásticamente. Esto nos aconseja nuevamente que utilizar datos previos a esta fecha solo resultaría en problemas para el modelo.

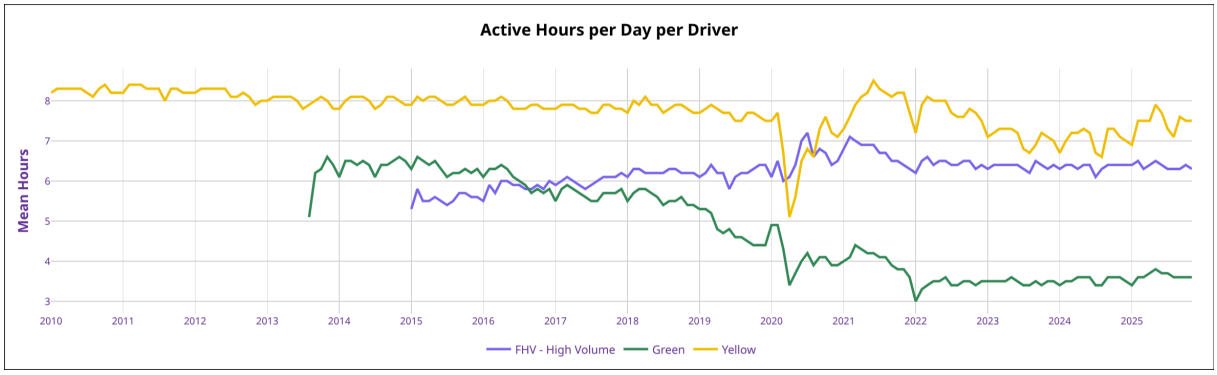

Figura 6: Horas de trabajo vs Tiempo.

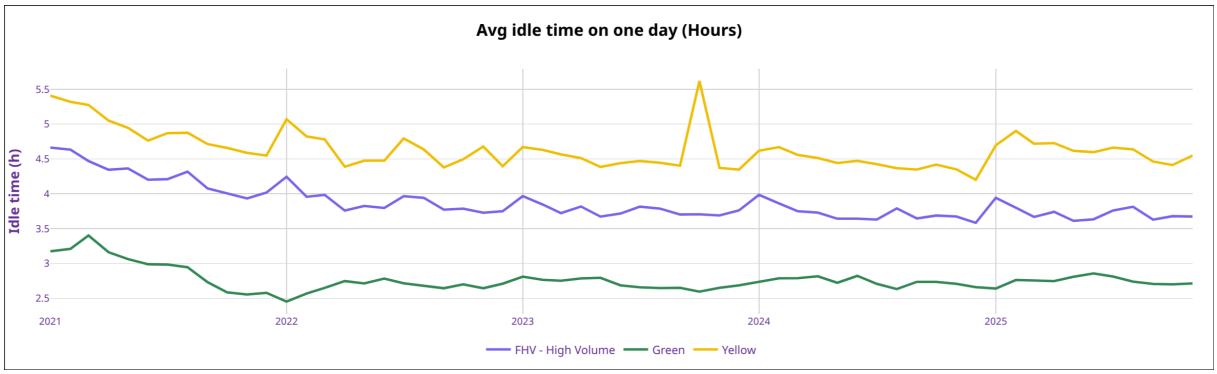

Figura 7: Horas de inactividad vs Tiempo.

3.2.7. Precios y beneficios

Respecto al precio, podemos observar un aumento progresivo del mismo, debido a la inflación constante en los precios que ha ocurrido estos años. Vemos además que los beneficios no aumentan de igual forma, sino que es ligeramente más atenuado su aumento, lo que aconseja que aumentaron las tasas para ser taxistas o conductor de una VTC.

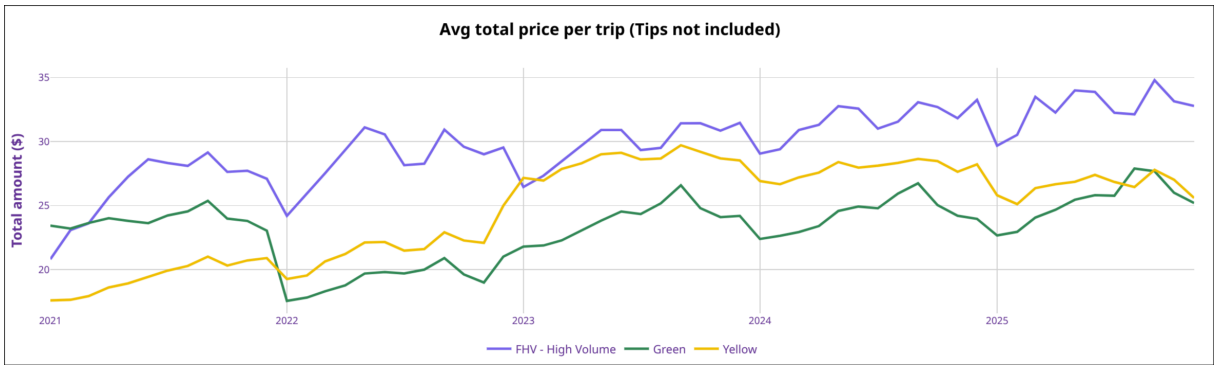

Figura 8: Precio medio vs Tiempo.

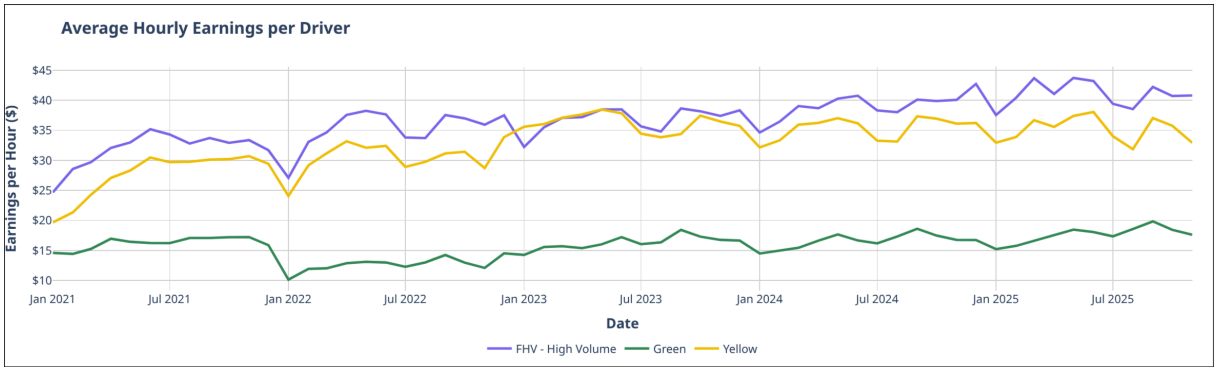

Figura 9: Beneficio medio vs Tiempo.

3.3. ¿Qué modelo de deep learning usaremos?

Usaremos TFT (Temporal Fusion Transformers) [2]. Este modelo fue investigado por el equipo de investigación de Google junto a la universidad de Oxford en 2019.

Este modelo se caracteriza por tener tres componentes:

- Todo el pasado conocido.
- Las variables futuras conocidas
- Invariantes temporales (por ejemplo una localización específica)

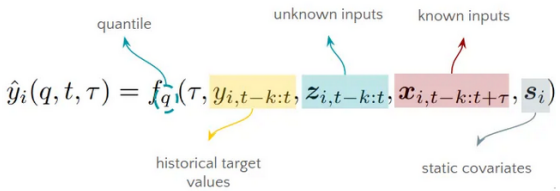

Figura 10: Formula original planteada por Google.

3.4. Resumen de Componentes

3.4.1. 1. Gated Residual Network (GRN)

Es el bloque de construcción principal. Su función es permitir que el modelo decida si una entrada requiere una transformación compleja o si debe pasar casi intacta (skip-connection).

$$\mathrm{GRN}(a, c) = \mathrm{LayerNorm}(a + \mathrm{GLU}(\eta_1))$$

Utiliza una puerta **GLU** para suprimir componentes irrelevantes y una activación **ELU** para mantener la estabilidad de los gradientes.

3.4.2. 2. Variable Selection Networks (VSN)

Selecciona automáticamente las variables más importantes en cada paso del tiempo, eliminando el ruido de entrada.

$$v_t = \mathrm{Softmax}(\mathrm{GRN}(\Xi_t))$$

Permite al modelo centrarse solo en los factores que realmente afectan a la predicción actual.

3.4.3. 3. Interpretable Multi-Head Attention

Mecanismo de atención que permite la explicabilidad. Al compartir los pesos de los valores (W_V), es posible promediar los pesos de atención para identificar qué momentos históricos son los más influyentes.

3.4.4. 4. Quantile Regression

El modelo no predice un solo valor, sino intervalos de confianza (ej. cuantiles 0.1, 0.5 y 0.9) para cuantificar la incertidumbre del pronóstico mediante la pérdida:

$$L(y, \hat{y}_q) = \sum_{i,t} \max\big(q(y - \hat{y}_q), (1-q)(\hat{y}_q - y)\big)$$

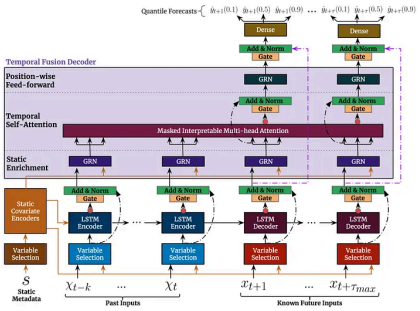

Figura 11: Esquema del Temporal Fusion Decoder y flujo de señales.

Entradas del Sistema:

- **Static Metadata:** Datos constantes (ej. ubicación).
- **Past Inputs:** Histórico observado con ruido.
- **Known Future:** Variables futuras conocidas (ej. días festivos, clima previsto).

3.5. ¿Cómo encajan los datos con nuestro modelo?

Con los datos que hemos nombrado anteriormente, podríamos plantear el esquema del modelo así:

- Invariantes temporales: La zona y el tipo de servicio
- Futuro conocido: La franja horaria que queremos predecir
- Futuro a conocer: Precio y demanda entre otras variables.

3.6. Otros modelos que podríamos usar:

En caso de que los recursos que tuviésemos fueran más limitados, existen otros modelos:

Time-series Dense Encoder Model (TiDE)[3,4]:

Modelo que diseñó Google en 2023 en respuesta del uso de Transformers. Es un modelo mucho más ligero y eficiente sacrificando un poco de rendimeinto al estar basado en el uso exclusivo de capas densas.

Encoder, un pasado codificado:

El encoder es el encargado de representar los invariantes temporales y todos los datos del pasado y transformarlo en un vector. Este paso tiene dos funciones clave:

- **Feature projection**: Básicamente se encarga de reducir la dimensión de las entradas dinámicas.
- **Dense encoder**: Una capa densa que genera un embedding.

Decoder, el futuro a predecir:

La entrada del decoder, como ocure en un autoencoder, es el embedding generado por el dense encoder, este embedding pasa por 2 fases:

- **Dense decoder**: Funcionando como el proceso inverso al encoder, transforma el embdedding a un vector por cada paso temporal.
- **Temporal Decoder**: Junta las variables futuras conocidas con el vector anterior para crear las predicciones.

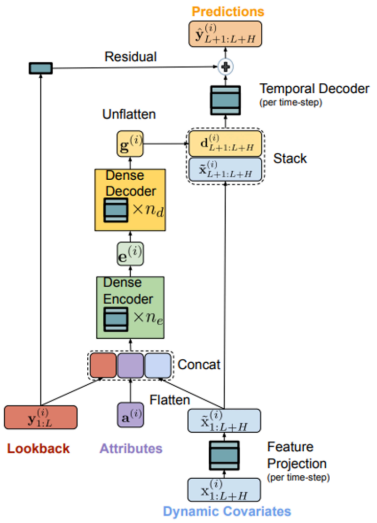

Figura 12: Esquema del TiDE y flujo de señales.

2. Además hemos probado otros modelos como N-Hits, N-Beats o usar LSTM sin invariantes temporales, pero al tener unos resultados peores en las pruebas iniciales los hemos dejado como última opción.

4. ANÁLISIS DEL MERCADO Y LA COMPETENCIA

El mercado del transporte en NYC está saturado de datos, pero fragmentado en su acceso. Mientras que las grandes plataformas dominan el volumen, crean «silos de información» que penalizan la eficiencia del conductor. NyFlow surge como una capa de inteligencia agnóstica para romper estas barreras.

4.1. Panorama del Mercado

Categorizamos a los competidores en tres niveles estratégicos:

1. **Los Gigantes (Silos de Datos):** Uber y Lyft. Proporcionan mapas de calor, pero solo dentro de su propio ecosistema. El conductor está «ciego» a lo que ocurre en la red de taxis o en la competencia.
2. **Rastreadores de Ingresos:** Apps como **Gridwise** o **Solo**. Ayudan a registrar gastos y ganancias históricas, pero carecen de capacidad predictiva en tiempo real basada en el dataset completo de la TLC.
3. **Despachadores Tradicionales:** Curb y Arro (Taxis amarillos/verdes). Se centran en la gestión de viajes (e-hailing), pero no ofrecen rutas predictivas ni análisis de rentabilidad por zona.

4.2. Matriz Comparativa

La siguiente tabla resalta cómo el uso de **Temporal Fusion Transformer (TFT)** y **Polars** otorga a NyFlow una ventaja decisiva:

Característica	Uber/Lyft	Gridwise	NyFlow
Datos Multi-plataforma	No	Parcial	**Completo (TLC)**
Precio Predictivo	Solo Interno	Histórico	**IA en Tiempo Real**
Latencia de Procesamiento	Baja	Alta	**Baja**

4.3. Nuestra Ventaja Competitiva: El Efecto «Caja de Cristal»

A diferencia de los algoritmos de «Caja Negra» de Uber, que priorizan el beneficio de la plataforma, NyFlow ofrece un enfoque de **«Caja de Cristal»**:

- **Simetría de Información:** Entregamos al conductor los mismos macro-datos que posee la ciudad.
- **Superioridad del TFT:** Mientras la competencia usa promedios simples, nuestro modelo entiende relaciones complejas entre los datos, permitiendo añadir información relevante y que este encuentre la relación aparente con nuestra variable objetivo.
- **Transparencia total:** Nuestras tecnologías y datos son de libre uso, lo que asegura la fidelidad tanto de los datos como del modelo.

4.4. Análisis DAFO:

Fortalezas
- Arquitectura de IA superior (TFT).
- Plataforma agnóstica (independiente).
- Integración profunda con datos TLC.

Debilidades
- Nuevo entrante en el mercado.
- Dependencia de la latencia de datos públicos.

Oportunidades
- Implementación de tarifas de congestión en NYC.
- Alianzas con flotas de taxis locales.

Amenazas
- Cambios en las políticas de datos abiertos de la TLC.
- Clonación de funciones por parte de las grandes apps.

5. ANÁLISIS FINANCIERO Y ESTRATEGIAS

Una vez tenemos detallado toda la parte técnica y las ideas generales, hay que detallar

5.1. ¿Cuál será nuestro método de ingresos?

Nuestro modelo de ingresos se basa en el Software as a Service (SaaS) con una estructura de suscripción diseñada para fomentar la fidelidad del conductor y garantizar ingresos recurrentes. Todos los competidores usan métodos similares y han sido exitosos, por tanto es una propuesta segura.

Inicialmente, al ser una aplicación nueva ofreceremos un precio muy asequible, pero con el paso del tiempo, al igual que todos los comercios, aumentaremos en precio ajustándonos a la demanda y a la situación económica en ese momento.

Respecto a los tipos de suscripción, ofreceremos tanto mensual, como 3 meses, 6 meses y por último la anual. Las suscripciones más grandes llevan consigo un precio mensual inferior, para animar a los usuarios a contratar más meses nuestro servicio..

5.2. Estructura de Precios

Plan	Precio Final	Mensual
Mensual	$14.99	$14.99
Trimestral (3 meses)	$39.99	$13.33
Semestral (6 meses)	$69.99	$11.66
Anual	**$119.99**	**$9.99**

5.3. Justificación del Precio

El precio de la suscripción anual ($9.99/mes) es inferior al coste de un solo viaje promedio en Manhattan. Un conductor que utilice **NyFlow** recupera su inversión mensual en menos de **2 horas de trabajo**.

5.4. Estrategias de captación y fidelidad

Para captar a nuestros clientes proponemos ofrecer una **suscripción de 3 meses gratuita**, de esta manera los clientes pueden probar nuestra aplicación sin consecuencias monetarias.

Una vez tengamos usuarios suficientes ofreceremos **descuentos** con el paso del tiempo, por ejemplo, meses gratuitos o suscripciones más baratas si las contratan en un periodo de tiempo.

5.5. Análisis del Punto Muerto (Break-even)

El Punto Muerto es el nivel de actividad en el que los ingresos totales de **NyFlow** igualan a sus costes totales, resultando en un beneficio neto de cero. A partir de este punto, cada nuevo suscriptor genera beneficio directo para la empresa.

5.5.1. Definición de Parámetros

Para los costes fijos anuales tenemos que añadir al desglose de los costes de manteamiento los sueldos de los 5 fundadores, que en estados unidos suele rondar los 40000 $ brutos.

- **Costes Fijos (CF):** $245,000 anuales (Infraestructura fija + Salarios operativos + Gastos legales).
- **Ingreso Medio por Usuario (ARPU):** $132 anuales.
- **Coste Variable Unitario (CV):** $12 anuales (Comisiones de pago + Incremento marginal de cómputo en la nube).

5.5.2. Resultado del Cálculo

Aplicando la fórmula de rentabilidad:

$$\text{Punto Muerto} = \frac{\text{CF}}{\text{ARPU} - \text{CV}} = \frac{245000}{120} \approx 2,042$$

Esto en verdad es un punto muerto sin tener en cuenta los costes de adquisición de ese usuario, que serían unos 40 $ por usuario. Por tanto el verdadero punto muerto es el siguiente:

$$\text{Margen Real} = \$132 - (\$12 + \$40) = \$80$$

$$\text{Punto Muerto} = \frac{245000}{80} = 3063 \text{ usuarios}$$

Para alcanzar la rentabilidad, **NyFlow necesita mantener una base de 3063 suscriptores activos**.

5.6. Gastos y resultados financieros esperados

Esperamos que la aplicación tenga un aumento de usuarios considerable a lo largo del tiempo, con esto también esperamos un aumento de ingresos que pueda cubrir nuestros gastos.

5.6.1. Justificación de las Proyecciones

Nuestras estimaciones no son arbitrarias; se basan en tres pilares de datos reales del mercado de Nueva York:

1. **TAM (Mercado Total Direccionable):** NYC cuenta con 100,000 licencias activas de la TLC (Taxis + VTC).
2. **Eficiencia del Producto:** Basándonos en el análisis del modelo **Temporal Fusion Transformer** (TFT), estimamos que el conductor recupera el coste anual de la suscripción en menos de **5 horas de conducción optimizada**.

5.6.2. Proyecciones a 3 Años (P&L)

A continuación se presenta la previsión de resultados. El **Punto de Equilibrio (Break-even)** se sitúa en el mes 18, con una base crítica de 1,250 usuarios activos.

Concepto (USD)	**Año 1**	**Año 2**	**Año 3**
Usuarios Suscritos	1,500	5,000	12,000
Ingresos Totales	**$198,000**	**$660,000**	**$1,584,000**
Servidores y Gestión de Datos	$45,000	$85,000	$150,000
Adquisición de Clientes CAC	$60,000	$120,000	$250,000
Sueldos Equipo (5 fundadores)	$200,000	$250,000	$350,000
Costes Totales	**$305,000**	**$455,000**	**$750,000**
Ganancias Previstas (Neto)	**$107,000**	**$205,000**	**$834,000**

5.6.3. Justificación de Gastos

- **Costes de IA/Cloud:** Incluyen el entrenamiento recurrente del modelo TFT y la infraestructura de datos.
- **Marketing (CAC):** Estimamos un coste de adquisición de $40 por conductor, utilizando canales directos en aeropuertos (JFK/LGA) y publicidad segmentada para usuarios de Uber/Lyft Driver.
- **OpEx:** Cubre el mantenimiento del equipo de 5 fundadores y licencias legales/TLC necesarias para operar en NY.

5.7. Conclusión de Viabilidad

Viendo los pronósticos anuales, se podría tomar la decisión estratégica de privar al equipo de sus sueldos el primer año para no entrar en números rojos. Respecto al resto de años se ve como el comercio es viable, al punto de que en tres años hay ganancias notables.

6. ROADMAP

El plan de desarrollo se divide en dos fases, coincidiendo con la planificación de la asignatura.

6.1. Fase 1 (hasta mediados de Febrero)

Elaboración de esta propuesta de aplicación. Para ello, se lleva a cabo un análisis de mercado y se define una propuesta de valor. Dicha propuesta se respalda con una investigación técnica de viabilidad (Véase Sección 3) junto con un ejercicio de extracción, procesado y visualización de los datos.

En paralelo, se ha empezado a implementar un prototipo de aplicación con FastAPI como *backend* y *frontend* con tecnología web y Leaflet como principal librería para el visor de mapas.

También ha habido una labor de aprendizaje por parte de todo el equipo de tecnologías como Minio, Cloudera o PySpark.

6.2. Fase 2 (hasta finales de Abril)

Esta fase se dedicará principalmente al entrenamiento del modelo final, y su integración con la aplicación.

Se espera que se añadan más funcionalidades a la misma con el fin de cumplir con otros de los retos propuestos por Cloudera; principalmente los que tienen que ver con facilitar la cooperación con los servicios de emergencias de la ciudad de Nueva York, ofreciendo rutas alternativas a nuestros conductores que no interfieran en operaciones de emergencia.

6.2.1. Entrenamiento del modelo

El modelo por el que apostamos, TFT, tarda en entrenarse con GPU una hora por mes de volumen de datos. Como planeamos usar un entorno de Cloudera en CPU, se estima que este tiempo se estire exponencialmente. Por ello, trabajaremos también con TiDE como segundo modelo, también entrenándolo en Cloudera.

En cualquier caso, según las pruebas realizadas, hemos llegado a la conclusión de que lo óptimo es entrenar varios modelos por cada característica que queramos predecir para obtener mejores resultados en las predicciones individuales.

6.2.2. La aplicación

El *backend* con FastAPI que se está desarrollando nos facilitará la integración del modelo una vez entrenado.

En cuanto a la aplicación en sí, planeamos continuar con el visor web para tener preparada una demo técnica y más adelante valorar la migración a una aplicación móvil nativa desarrollada con Flet, una nueva librería Python que permite hacer aplicaciones Flutter(IOS y Android). Flet está todavía en desarrollo pero se espera que la primera versión salga este año.

6.2.3. Flujo de datos

De cara a ofrecer el servicio que queremos, es indispensable tener la tecnología para procesar nuevos datos y usarlos en las predicciones de nuestros modelos. Aunque no es el objetivo de esta fase, se planteará cómo debería ser el proceso.

Los datos vendrían principalmente de dos fuentes:

- Datos semi-estructurados desde NYC OpenData Portal: con un retraso variable de dos meses. Los nuevos datos se usarán para ir ajustando el modelo y evitar el *data drift*.
- Datos de nuestros conductores: procesamiento en tiempo real. Estos datos sirven para ajustar recomendaciones en tiempo real y mejorar nuestros servicios.

7. BIBLIOGRAFÍA Y WEBGRAFÍA

1. https://automarketplace.substack.com/i/182931807/utilization-rate-ur-steady-at-55
2. https://medium.com/dataness-ai/understanding-temporal-fusion-transformer-9a7a4fcde74b
3. https://medium.com/@nasdag/tide-revolutionizing-long-term-time-series-forecasting-with--simple-mlp-architectures-21259cbe575b
4. https://towardsdatascience.com/tide-the-embarrassingly-simple-mlp-that-beats--transformers-7db77d588079/